


Arco pedagógico: Neural Operators, FNO y representaciones Bochner-like

De operadores continuos a modelos espacio-temporales y spectrum sensing

Documento de guía conceptual y secuencia de aprendizaje



Arco pedagógico depurado: fundamentos → FNO → dinámica S-T → spectrum sensing → representaciones adaptativas.

1. Propósito del arco pedagógico

El objetivo es construir una progresión compacta y técnicamente consistente que permita pasar desde la noción matemática de operador entre espacios de funciones hasta el uso de Neural Operators en dinámica espacio-temporal, con énfasis en Fourier Neural Operators (FNO), spectrum sensing y representaciones alternativas basadas en reducción dimensional y Bochner/Random Fourier Features (RFF).

La secuencia busca que cada concepto aparezca únicamente cuando es necesario para sostener el siguiente. El punto de llegada no es memorizar una arquitectura, sino poder razonar sobre qué representación y qué operador convienen para un problema físico o estocástico dado.

2. Línea temática general

Funciones → Operadores continuos → Neural Operators → FNO → Dinámica espacio-tiempo → Modelos estocásticos → Spectrum sensing → Reducción dimensional → Bochner/RFF → NO espectral adaptativo

Etapas	Tema	Meta conceptual	Objeto matemático
I	Fundamentos funcionales	Distinguir función, operador y espacio de funciones.	$\mathcal{G} : a(\cdot) \mapsto u(\cdot)$
II	Neural Operators	Entender <i>operator learning</i> y la idea de invariancia respecto de la discretización.	$\mathcal{G}_\theta \approx \mathcal{G}$
III	FNO	Comprender el kernel integral y su representación de Fourier.	$\mathcal{K}_\theta v = \mathcal{F}^{-1}[R_\theta(k)\mathcal{F}(v)]$
IV	Espacio y tiempo	Separar coordenadas físicas, frecuencia conjugada y profundidad de red.	$v_\ell(x, t) \leftrightarrow \hat{v}_\ell(k, \omega)$

Etapa	Tema	Meta conceptual	Objeto matemático
V	Dinámica ST	Formular evolución autoregresiva y condicionamiento externo.	$u_{t+1} = \mathcal{G}_\theta(u_t, z_t) + \varepsilon_t$
VI	Spectrum sensing	Tratar el espectro como campo f - x - t susceptible de <i>operator learning</i> .	$S(x, f, t) \mapsto S(x, f, t + \Delta t)$
VII	Representaciones reducidas	Comparar POD/PCA, GNO y bases espectrales.	$u \approx \sum_r c_r \phi_r$
VIII	Bochner/RFF	Generalizar la base espectral fija hacia muestreo o medidas aprendidas.	$\omega_j \sim p_\theta(\omega)$

3. Módulo I — De funciones a operadores continuos

Objetivo. Distinguir una función ordinaria de un operador y reconocer que un Neural Operator aproxima transformaciones entre funciones completas.

Núcleo matemático

$$F : \mathbb{R}^n \rightarrow \mathbb{R}^m, \quad \mathcal{G} : \mathcal{A} \rightarrow \mathcal{U}, \quad a(\cdot) \mapsto u(\cdot).$$

- Espacios de funciones: $C(D)$, $L^2(D)$ u otros espacios funcionales adecuados al problema.
- Propiedades relevantes: continuidad, linealidad/no linealidad, acotación y localidad/no localidad.
- Un operador solución de una PDE es el ejemplo conceptual principal: parámetros o condiciones de entrada $\rightarrow$ campo solución.

Checkpoint: Explicar por qué aprender $a(\cdot) \mapsto u(\cdot)$ es conceptualmente distinto de aprender $x \mapsto y$.

4. Módulo II — Neural Operators

Objetivo. Entender el aprendizaje de operadores y reconocer tres familias representativas sin mezclar sus mecanismos internos.

- **DeepONet:** descompone la aproximación del operador mediante una *branch network* y una *trunk network*.
- **Fourier Neural Operator (FNO):** parametriza una parte del operador integral en una representación de Fourier.
- **Graph Neural Operator (GNO):** aproxima interacciones integrales sobre puntos o nodos, útil para dominios irregulares.

Checkpoint: Identificar qué arquitectura sería más natural para una malla regular, una geometría irregular y una evaluación en coordenadas arbitrarias.

5. Módulo III — Fourier Neural Operator

Objetivo. Comprender el FNO como una arquitectura de *operator learning* que alterna representaciones físicas y espectrales.

Kernel integral y mecanismo espectral

$$(\mathcal{K}v)(x) = \int_D K(x, y) v(y) dy.$$

Cuando el kernel es compatible con una estructura de convolución, la transformada de Fourier convierte la convolución en una multiplicación espectral:

$$\mathcal{K}_\theta v = \mathcal{F}^{-1} [R_\theta(k) \mathcal{F}(v)(k)].$$

El FNO aprende $R_\theta(k)$, una transformación sobre los modos espectrales retenidos.

Dominio físico vs. dominio espectral

$$v(x) \longleftrightarrow \widehat{v}(k).$$

- x : coordenada del dominio físico o matemático.
- k : frecuencia espacial o número de onda conjugado a x .
- Si la variable es temporal, $t \leftrightarrow \omega$; si es espacio-tiempo, $u(x, t) \leftrightarrow \widehat{u}(k, \omega)$.

“Espacial” no significa posición de una capa dentro de la red. La profundidad de la red se representa con otro índice, por ejemplo ℓ .

6. Módulo IV — Formulación completa de una Fourier Layer

Objetivo. Interpretar cada término de una capa FNO y separar coordenadas físicas de profundidad neuronal.

$$v_{\ell+1}(x) = \sigma \left[W_\ell v_\ell(x) + \mathcal{F}^{-1} \left(R_{\theta, \ell}(k) \mathcal{F}(v_\ell)(k) \right) \right] \quad (1)$$

- ℓ : índice de capa o profundidad de la red.
- x : coordenada donde se evalúa el campo latente.
- $R_{\theta, \ell}(k)$: transformación lineal aprendida sobre modos espectrales, para parámetros fijos.
- $W_\ell v_\ell(x)$: mezcla local de canales en el dominio físico.
- σ : activación no lineal aplicada después de combinar los caminos local y espectral.

Interpretación central: el FNO combina filtrado o *global mixing* lineal en Fourier con procesamiento local y no lineal en el dominio físico. La composición de capas produce un operador globalmente no lineal.

Checkpoint: Explicar por qué “FNO = transformación no lineal en frecuencia” es una descripción incompleta.

7. Módulo V — Configuraciones autoregresivas y espacio-temporales

Objetivo. Pasar de operadores estáticos a operadores de evolución temporal sobre campos completos.

$$u_{t+1}(x) = \mathcal{G}_\theta(u_t(x)), \quad u_{t+1} = \mathcal{G}_\theta(u_t, u_{t-1}, \dots, u_{t-p+1}).$$

En una formulación espacio-temporal, el objeto es un campo $u(x, t)$. Si se transforma conjuntamente, sus variables conjugadas son (k, ω) :

$$u(x, t) \longleftrightarrow \widehat{u}(k, \omega).$$

Checkpoint: Distinguir forecasting de un escalar de forecasting de un campo funcional completo.

8. Módulo VI — Formulaciones estocásticas S–T

Objetivo. Introducir incertidumbre, innovación y covariables externas sin confundir un FNO determinista con un modelo probabilístico completo.

$$U(x, t) = m(x, t) + \varepsilon(x, t),$$

$$p(U_{t+1} \mid U_t, z_t), \quad U_{t+1} = \mathcal{G}_\theta(U_t, z_t) + \varepsilon_t.$$

- z_t puede contener forcing, contexto espacial, condiciones ambientales, variables del canal u otras entradas exógenas.

- Un FNO estándar puede aproximar una media condicional o dinámica determinista; una distribución predictiva requiere una extensión probabilística.

Checkpoint: Identificar qué parte corresponde a la dinámica aprendida, qué parte al forcing y qué parte a la incertidumbre.

9. Módulo VII — Superficies de regresión interconectadas por Neural Operators

Objetivo. Construir una interpretación geométrica donde cada instante o condición define una superficie multidimensional y el NO aprende la transición entre superficies.

$$\mathcal{S}_t(x, f) \xrightarrow{\mathcal{G}_\theta} \mathcal{S}_{t+1}(x, f).$$

Una arquitectura práctica puede usar codificación, operador y decodificación:

$$\mathcal{S}_t \rightarrow \text{Encoder} \rightarrow z_t \rightarrow \text{Neural Operator} \rightarrow z_{t+1} \rightarrow \text{Decoder} \rightarrow \mathcal{S}_{t+1}.$$

- La superficie puede ser una regresión de potencia, ocupación, probabilidad o cualquier campo continuo estimado.
- Usar varias superficies pasadas permite representar memoria temporal.

Checkpoint: Formular entradas, salida y variable de evolución de una superficie concreta.

10. Módulo VIII — Spectrum sensing como problema de operator learning

Objetivo. Reformular spectrum sensing como estimación, reconstrucción o forecasting de campos espectrales en frecuencia, espacio y tiempo.

$$\begin{aligned} S &= S(x, f, t), \\ S(x, f, t - T : t) &\xrightarrow{\mathcal{G}_\theta} S(x, f, t + 1 : t + H), \\ y &= \Theta S + \varepsilon, \quad (y, \Theta) \xrightarrow{\mathcal{G}_\theta} \widehat{S}. \end{aligned}$$

- Forecasting de ocupación espectral.
- Reconstrucción de espectro parcialmente observado.
- Detección de interferencia o anomalías.
- Condicionamiento por SNR, ubicación, tráfico, estado del canal o fuentes conocidas.

Nota conceptual: “spectral” en FNO se refiere a una representación matemática en Fourier. No debe confundirse automáticamente con “RF spectrum”; ambas nociones pueden coincidir en una aplicación, pero no son equivalentes. **Checkpoint:** Especificar claramente cuál es la coordenada física, cuál es la frecuencia RF y cuál es la frecuencia conjugada usada por el operador.

11. Módulo IX — Representaciones alternativas y reducción de carga computacional

Objetivo. Separar tres rutas distintas de reducción o generalización: bases empíricas, grafos y representaciones espectrales tipo Bochner.

11.1 PCA / POD / KL

$$u(x) \approx \sum_{r=1}^R c_r \phi_r(x), \quad R \ll N.$$

La dinámica puede aprenderse sobre los coeficientes de una base de baja dimensión. Es una estrategia de *reduced-order modeling*, no una representación Bochner.

11.2 Graph Neural Operator

$$v_{\ell+1}(x_i) = \sigma \left(W v_{\ell}(x_i) + \sum_j K_{\theta}(x_i, x_j) v_{\ell}(x_j) \right).$$

Es apropiado cuando las observaciones se encuentran en ubicaciones irregulares, por ejemplo una red de sensores o SDR geográficamente distribuidos.

11.3 Bochner y Random Fourier Features

$$k(x - x') = \int e^{i\omega^\top(x-x')} d\mu(\omega), \quad \omega_j \sim p(\omega),$$
$$k(x, x') \approx \Phi(x)^\top \Phi(x').$$

Las RFF aproximan mediante Monte Carlo una representación espectral asociada a un kernel estacionario. A diferencia de la FFT, no requieren una rejilla uniforme de frecuencias.

Checkpoint: Explicar por qué PCA/POD, GNO y RFF son alternativas distintas aunque todas puedan reducir o reorganizar la representación.

12. Módulo X — De FNO a un Neural Operator Bochner-like

Objetivo. Explorar una generalización donde los modos utilizados por el operador no estén restringidos a una rejilla Fourier fija.

FNO: $k_1, \dots, k_K$ (modos Fourier fijos),

RFF-like: $\omega_j \sim p(\omega)$, Adaptativo: $\omega_j \sim p_{\theta}(\omega)$.

La hipótesis conceptual es que el modelo puede aprender no solo la transformación aplicada a cada modo, sino también una distribución o medida que concentre capacidad en regiones espectrales relevantes.

$$c_j = \int e^{-i\omega_j^\top x} v(x) dx, \quad \tilde{c}_j = A_{\theta}(\omega_j) c_j,$$
$$v'(x) \approx \sum_j e^{i\omega_j^\top x} \tilde{c}_j.$$

Extensión espacio-temporal

$$(k_j, \omega_j) \sim p_{\theta}(k, \omega).$$

Una medida conjunta puede representar dependencias entre escalas espaciales y temporales sin imponer separabilidad. En spectrum sensing, esta idea podría extenderse a representaciones donde frecuencia RF, espacio y tiempo estén modelados de forma conjunta, siempre distinguiendo las coordenadas físicas de sus variables espectrales conjugadas.

Checkpoint: Formular qué se gana y qué se pierde al reemplazar una base FFT fija por muestreo o aprendizaje de una medida espectral.

13. Síntesis del arco pedagógico

El recorrido parte de una pregunta básica —qué significa aprender un operador— y termina en una pregunta de investigación: si el FNO aprende transformaciones sobre una base Fourier predefinida, ¿puede reducirse la carga computacional o mejorar la adaptación al fenómeno mediante una base empírica, una estructura de grafo o una medida espectral aprendida?

**Funciones → Operadores → NO → FNO → S-T → Estocástico → Spectrum sensing →
Representaciones reducidas → Bochner/RFF**

El criterio pedagógico es progresivo: cada módulo debe dominarse antes de introducir el siguiente. El estudiante debe terminar siendo capaz de justificar la elección de representación y arquitectura según la geometría del dominio, la dinámica, la incertidumbre y el presupuesto computacional.

14. Resultados de aprendizaje esperados

- Definir formalmente un Neural Operator y distinguirlo de una red neuronal vectorial convencional.
- Interpretar una Fourier Layer término por término y diferenciar dominio físico, dominio espectral y profundidad de red.
- Formular configuraciones autoregresivas y espacio-temporales, incluyendo variables exógenas e incertidumbre.
- Reformular spectrum sensing como un problema de *operator learning* sobre campos.
- Comparar FNO, reduced-order models, GNO y representaciones RFF según el dominio y el coste computacional.
- Plantear de forma matemáticamente consistente una generalización Bochner-like con medidas espectrales muestreadas o aprendidas.

15. Secuencia sugerida de enseñanza

Sesión	Contenido central
Sesión 1	Funciones, espacios funcionales y operadores continuos
Sesión 2	Neural Operators: DeepONet, FNO y GNO
Sesión 3	Fourier Layer: kernel, FFT, dominio físico y dominio espectral
Sesión 4	Dinámica autoregresiva y formulación espacio-temporal
Sesión 5	Modelos estocásticos, forcing y variables exógenas
Sesión 6	Spectrum sensing como campo espacio-frecuencia-tiempo
Sesión 7	PCA/POD, Graph NO y reducción de representación
Sesión 8	Bochner, RFF y propuesta de Neural Operator espectral adaptativo